

PHASES 4, 5 & 6

Modélisation, Évaluation et Déploiement

Phase 4 — Modélisation

4.1 Introduction

La modélisation consiste à entraîner un algorithme à reconnaître les comportements associés au risque de défaut de paiement à partir de données historiques.

 **Objectif** Le modèle apprend à estimer automatiquement une probabilité de défaut pour chaque nouveau client.

4.2 Comparaison des modèles

Trois modèles ont été testés afin de sélectionner la meilleure solution pour le pré-scoring BNPL.

Modèle	AUC-ROC	F1	Retenu
Régression logistique	0,6500	0,19	Non
XGBoost	0,7966	0,44	Non
LightGBM	0,8222	0,49	✓ Oui

4.3 Modèle retenu — LightGBM

Le modèle LightGBM a été retenu car il offre les meilleures performances tout en permettant l'intégration de contraintes métier bancaires.

4.3.1 Paramètres principaux

Les paramètres suivants ont été utilisés pour optimiser les performances du modèle :

Paramètre	Valeur	Description
n_estimators	2500	Nombre d'arbres de décision
learning_rate	0,02	Apprentissage lent et précis
num_leaves	63	Nombre maximal de branches
subsample	0,8	80 % des données par arbre

 **Avantage principal** LightGBM permet d'imposer des règles métier cohérentes avec les pratiques bancaires.

Phase 5 — Évaluation

5.1 Métriques d'évaluation

La qualité du modèle est mesurée à l'aide de plusieurs indicateurs statistiques tels que l'AUC-ROC, la précision et le rappel.

 **AUC-ROC** Une AUC proche de 1 signifie que le modèle distingue efficacement les bons clients des clients risqués.

5.2 Résultats du modèle

Les performances détaillées du modèle LightGBM sont présentées ci-dessous.

Classe	Précision	Rappel	F1-score
Non-défaut	0,92	0,85	0,88
Défaut	0,41	0,60	0,49

Le modèle atteint une AUC de 0,8222, ce qui représente une très bonne performance pour un système de pré-scoring bancaire.

 **Interprétation** Le modèle ne remplace pas l'analyste crédit mais sert d'outil d'aide à la décision.

Phase 6 — Déploiement

6.1 Déploiement du modèle

Le modèle entraîné est intégré dans un microservice Flask afin d'être accessible par les applications UIB BNPL.

6.2 Fonctionnement global

Lorsqu'un dossier est soumis, le serveur applique automatiquement les étapes suivantes : validation, transformation des données, prédiction et génération du score final.

 **Pipeline** Le serveur applique les mêmes traitements que ceux utilisés pendant l'entraînement du modèle.

6.3 Perspectives

Les prochaines versions intégreront des mécanismes d'explicabilité SHAP et des modèles de détection d'anomalies afin d'améliorer encore la fiabilité du système.

 **Conclusion** Le système BNPL UIB constitue une première base opérationnelle de pré-scoring automatisé adaptée au contexte bancaire.